

STUDIENARBEIT

Unterstützt die Visualisierung von
Quellenbezügen einer künstlichen
Intelligenz, Nutzer bei der
Erkennung von
KI-Halluzinationen?

Leon Salenbacher und Rosalie Fischer

6. Oktober 2026

<i>Kurs</i>	TINF24C
<i>Matrikelnummer</i>	8368668, 3045197
<i>Bearbeitungszeitraum</i>	12 WOCHEN
<i>Betreuer der DHBW</i>	DANIEL AMOR

Inhaltsverzeichnis

Abkürzungsverzeichnis	4
Ehrenwörtliche Erklärung	5
Zusammenfassung/Abstract	6
1 Einleitung	7
2 Grundlagen	7
2.1 Large-Language Modelle	7
2.2 Systemkonfiguration	7
2.3 Halluzinationen	7
2.4 Vertrauen in Aussagen	7
3 Umsetzung	7
3.1 Wahl des Modells	7
3.1.1 Länge des Kontextfensters	8
3.1.2 Nachdenken des Modells	8
3.2 Short Story	8
3.3 Wahl des Studientyps	9
3.4 Nutzerstudie - Aufbau	10
3.4.1 Nutzerstudie - Tools	10
3.4.2 Nutzerstudie - Hypothesen	10
3.5 Probleme	11
4 Diskussion	11
4.1 Nutzerstudie - Ergebnisse	11
4.2 Andere Tools/Umsetzungen	11
4.3 Mögliche Erweiterungen	11
5 Schluss	11

Abbildungsverzeichnis

Tabellenverzeichnis

1	Ergänzung zur KI Verwendung	5
2	Verschiedene Geschichten die getestet wurden	9
3	Testfälle der Nutzerstudie	10
4	Übersicht der zu untersuchenden Hypothesen	11

Listings

Abkürzungsverzeichnis

LLM Large Language Model

KI Künstliche Intelligenz

Ehrenwörtliche Erklärung

Werkzeug	Beschreibung der Nutzung
Google Gemini Flash	Unterstützung bei der Entwicklung von <i>FrostFlow</i> ; Nutzung von Gemini Flash zur Korrektur- und Formulierungshilfe (gesamt)
Claude Sonnett 4.6/5	Unterstützung bei der Entwicklung von <i>FrostFlow</i>
Google Scholar Labs	Recherche für Literatur (Kapitel 2.3)
Perplexity	Nutzung von Perplexity zur Korrektur- und Formulierungshilfe (gesamt)

Tabelle 1: Ergänzung zur KI Verwendung

Wir versichern hiermit ehrenwörtlich, dass wir die wissenschaftliche Arbeit mit dem Thema („XXX“) selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt haben. Wir erklären, dass wir die Übernahme wörtlicher Zitate aus der Literatur sowie die Verwendung der Gedanken anderer Autoren an den entsprechenden Stellen innerhalb der Arbeit gekennzeichnet haben, diese wissenschaftliche Arbeit bei keiner anderen Prüfung vorgelegt haben, uns aktiv über die Leistungsfähigkeit und Beschränkungen ggf. verwendeter KI-Systeme informiert haben, die aus KI-Systemen stammenden Inhalte gemäß den hier formulierten Regelungen zu Quellenangaben und -verzeichnissen gekennzeichnet haben und überprüft haben, dass die aus KI-Systemen stammenden Inhalte korrekt sind und uns bewusst ist, dass wir als Autoren dieser Arbeit die Verantwortung für in ihr gemachte Angaben und Aussagen tragen. Wir sind uns bewusst, dass eine falsche Erklärung rechtliche Folgen haben wird.

Stuttgart, den XX.XX.2027

.....
(Ort, Datum)

.....
(Leon Salenbacher, Rosalie Fischer)

Zusammenfassung/Abstract

Diese Arbeit beschreibt die Untersuchung einer Mittels einer Nutzerstudie soll untersucht werden.

This paper describes the

1 Einleitung

Künstliche Intelligenz hat viele Bereiche des Lebens und der täglichen Arbeit revolutioniert. Die Automatisierung von Prozessen, das schreiben von Code oder ein persönlicher Künstliche Intelligenz (KI)-Agent, der Mails zusammenfasst, Aufgaben erstellt oder Code in Rust neuschreibt, künstliche Intelligenz wird in allen Lebensbereichen genutzt. Ihre Fähigkeit auf sehr menschliche Art und Weise mit uns interagiert lässt schnell das Gefühl von Sicherheit zu. Wie Quellen genutzt werden ist bei vielen Agenten oder Large Language Model (LLM) nicht

2 Grundlagen

2.1 Large-Language Modelle

Large Language Modelle beschreibt ein Modell, welches aufgrund von mathematischen Berechnungen, Text erzeugen kann. [Quelle] Ein solches Modell hat durch Training erlernt auf Grundlage von Statistik, Wortfolgen zu erstellen. Dieses Wissen und diese Möglichkeit zur Erzeugung wird genutzt um mit dem User zu interagieren. Einsatzgebiete sind unter anderem die Erzeugung von Code, das Erstellen von Schriftstücken aller Art so auch Gedichte oder Geschichten oder auch zum Beweis von mathematischen Problemen (so soll angeblich ein [Millenium-Problem](#) von OpenAI gelöst worden sein).

2.2 Systemkonfiguration

2.3 Halluzinationen

2.4 Vertrauen in Aussagen

3 Umsetzung

3.1 Wahl des Modells

- Qwen vl-4B

-
- Mistral 3B
 - Gemma 4 12B QAT
 - smollm2-360m-instruct

3.1.1 Länge des Kontextfensters

3.1.2 Nachdenken des Modells

In diesem Projekt wurde sich gegen das Reasoning des Modells entschieden. Zum einen steigt die Antwortzeit durch das Reasoning exponentiell und es werden mehr Token für eine Antwort benötigt. Daneben unterstützen viele der kleineren Modelle diese Fähigkeit in der Regel auch nicht. Zudem soll das Modell/die Modelle nicht durch das Nachdenken mögliche Fehler/Halluzinationen erkennen können. Ziel dieser Arbeit ist jede kleine Hallizination zu erkennen und zu nutzen, da wäre das Nachdenken des Modells eher hinderlich.

3.2 Short Story

Gechichte	Kurze Zusammenfassung	Modellen bekannt?
Galiotova pesan (Vladimir Nator)	Eine Geschichte über eine Vorstellung über eine Reise in einem Boot	Gut geeignet
Šuma Striborova (Branko Ćopić)	Der Sohn verliebt sich in ein Mädchen das in der Wirklichkeit eine verzauberte Schlange ist. Seine Mutter kämpft gegen die Magie und versucht ihren Sohn zu retten.	Eher schlecht geeignet, wobei Qwen 3-vl-4B es nicht kennt

Gechichte	Kurze Zusammenfassung	Modellen bekannt?
Zlatna lađa (Vladimir Nazor)	Er möchte dass sein Sohn die Welt erlebt, weil er es nicht konnte.	
Ježeva kućica (Branko Ćopić)	Igel, stolz auf sein Haus. Der Fuchs versucht ihn dazu zu bringen, sein Haus zu verlassen, weil sie ein “einfaches Leben” für wertlos hält.	

Tabelle 2: Verschiedene Geschichten die getestet wurden

3.3 Wahl des Studientyps

Die Studie wurde nach dem Within-Subjects-Design aufgebaut. Hier durchläuft jede Testperson alle Bedingungen der unabhängigen Variablen wie beispielsweise die Reaktionszeit oder die Korrektheit der Klassifikation. So fungiert jede Testperson als ihre eigene Kontrolle. Es wurde keine separate Kontrollgruppe befragt.

Der Vorteil des Designs liegt darin, dass personenbezogene Störvariablen wie Vorwissen über [KI](#), die Kurzgeschichten oder das persönliche Empfinden gegenüber den Ergebnissen der [KI](#), über die Bedingungen konstant gehalten werden. [Quelle] Dieser Effekt führt dazu, dass die Fehlervarianz reduziert wird und präzisere Aussagen über den tatsächlichen Effekt der Quellenbelege getroffen werden kann. [Quelle]

Jedoch bringt dieses Design auch Nachteile mit, die die Ergebnisse beeinflussen können. Zunächst sei der Carry-over-Effekt zu erwähnen, bei dem sich Effekte aus dem ersten Testlauf auf die Ergebnisse des zweiten Testlaufs übertragen. [<https://statistikguru.de/lexikon/over-effekt.html>] Um dieses Problem einzudämmen wurden zwei unabhängige Kurzgeschichten gewählt und die Fragen an die [KI](#) angepasst. Darüber hinaus kann der Hawthorne-Effekt zu veränderten/verfälschten Ergebnissen führen.

Weiter können die Ergebnisse nur begrenzt generalisiert werden.

3.4 Nutzerstudie - Aufbau

- Gewählte Stichprobengröße: 50 Teilnehmende
- Erfassung von Störvariablen: Vorkenntnisse von KI und Kurzgeschichten

Angabe für den User	Grad der Nachweisbarkeit
Antwort	Ohne Quelle belegt
Antwort	Mit Quelle, aber ohne Quellenmarkierung
Antwort	Mit aussagenbezogener Quellenmarkierung
Antwort	Mit Quellenmarkierung und Quellenvorschau

Tabelle 3: Testfälle der Nutzerstudie

3.4.1 Nutzerstudie - Tools

3.4.2 Nutzerstudie - Hypothesen

Im folgenden werden die vier Hypothesen beschrieben, die untersucht werden sollen:

ID	Ausformulierte Hypothese
H1	Nutzende erkennen mit Quellenvisualisierung mehr Halluzinationen als Nutzende ohne diese Bedingungen.
H2	Quellenvisualisierung erhöht die subjektive Entscheidungssicherheit.
H3	Belegte Aussagen werden als vertrauenswürdiger Bewertet und dieser Effekt ist mit Visualisierung stärker.

ID	Ausformulierte Hypothese
H4	Eine Visualisierung unbelegter Aussagen erhöht zwar die Halluzinationserkennung, führt aber auch zu mehr Fehlmeldungen bei korrekt formulierten Aussagen.

Tabelle 4: Übersicht der zu untersuchenden Hypothesen

3.5 Probleme

4 Diskussion

4.1 Nutzerstudie - Ergebnisse

4.2 Andere Tools/Umsetzungen

4.3 Mögliche Erweiterungen

5 Schluss